

Manual de Flujo KNIME

Datos

Name	Type	# Missing values	# Unique values	Minimum	Maximum	25% Quantile	50% Quantile (...	75% Quantile	Mean	Mean Absolut...	Standard Devi...	Sum	10 most com...
id_cliente	Number (Integer)	0	5000	1	5,000	1,250.25	2,500.5	3,750.75	2,500.5	1,250	1,443.52	12,502,500	1 (1, 0.02%), 2 (1,
fecha_solicitud	String	0	1065										2024-02-27 (13, 0
edad	Number (Integer)	0	52	18	69	31	44	57	43.857	13.109	15.131	219,284	60 (128, 2.56%), 1
genero	String	0	2										Femenino (2523,
estado_civil	String	0	4										Soltero (1307, 26
ciudad	String	0	6										Cuenca (872, 17,
ingresos_mensu	Number (Integer)	0	3308	500	6,000	1,891	3,258.5	4,619	3,260.394	1,372.208	1,585.621	16,301,970	2,232 (7, 0.14%),
gastos_mensual	Number (Integer)	0	2736	301	4,000	1,231.25	2,168.5	3,072	2,153.597	931.119	1,076.66	10,792,984	374 (7, 0.14%), 1,
score_credicio	Number (Integer)	0	601	300	900	452	603	750	600.468	149.307	172.315	3,002,340	463 (20, 0.4%), 6
antiguedad_labor	Number (Integer)	0	31	0	30	8	15	22	14.924	7.579	8.787	74,619	9 (184, 3.68%), 1,

Estadísticas

► 1: File Table		🔗 Flow Variables											
Rows: 18		Columns: 14											
		Table											
Name	Type	# Missing values	# Unique values	Minimum	Maximum	25% Quantile	50% Quantile (...	75% Quantile	Mean	Mean Absolut...	Standard Devi...	Sum	10 most comm...
id_cliente	Number (Integer)	0	5000	1	5,000	1,250.25	2,500.5	3,750.75	2,500.5	1,250	1,443.52	12,502,500	1 (1, 0.02%), 2 (1,
fecha_solicitud	String	0	1065										2024-02-27 (13, 0
edad	Number (Integer)	0	52	18	69	31	44	57	43.857	13.109	15.131	219,284	60 (128, 2.56%), 1
genero	String	0	2										Femenino (2523,
estado_civil	String	0	4										Soltero (1307, 26
ciudad	String	0	6										Cuenca (872, 17,
ingresos_mensu	Number (Integer)	0	3308	500	6,000	1,891	3,258.5	4,619	3,260.394	1,372.208	1,585.621	16,301,970	2,232 (7, 0.14%),
gastos_mensual	Number (Integer)	0	2736	301	4,000	1,231.25	2,168.5	3,072	2,153.597	931.119	1,076.66	10,792,984	374 (7, 0.14%), 1,
score_credicio	Number (Integer)	0	601	300	900	452	603	750	600.468	149.307	172.315	3,002,340	463 (20, 0.4%), 6
antiguedad_labor	Number (Integer)	0	31	0	30	8	15	22	14.924	7.579	8.787	74,619	9 (184, 3.68%), 1,
tipo_empleo	String	0	4										Independiente (1
monto_solicitad	Number (Integer)	0	4759	1,003	49,998	12,885.25	25,793	38,305.5	25,625.072	12,487.733	14,335.463	128,125,361	7,285 (3, 0.06%),
plazos_meses	Number (Integer)	0	5	12	60	24	36	48	36.067	14.518	17.057	180,336	60 (1015, 20.3%),
productos_banca	Number (Integer)	0	7	1	7	2	4	6	3.978	1.711	1.995	19,891	3 (736, 14.72%),
mcra_historica	String	0	2										No (3756, 75.12%
canal_solicitud	String	0	3										Web (1691, 33.82
capacidad_pago	Number (Integer)	0	3567	-3,457	5,554	-315.5	1,120	2,496	1,101.797	1,598.228	1,939.256	5,508,986	2,156 (6, 0.12%),
credito_aprobado	Number (Integer)	0	2	0	1	0	1	1	0.53	0.493	0.499	2,650	1 (2650, 53.0%),

Tabla

Rows: 5000		Columns: 18																			
Table																		Statistics			
☐	#	RowID	id_cliente = Number (.)	fecha_sol_ = Date (dd-mm-yy)	edad = Number (.)	genero = String	estado_civil = String	ciudad	ingresos_ = Number (.)	gastos_m_ = Number (.)	score_cre_ = Number (.)	antigueda_ = Number (.)	tipo_empl_ = String	monto_so_ = Number (.)	plazo_me_ = Number (.)	☐	☐				
☐	1	Row0	1	2024-04-26	66	Masculino	Casado	Manta	2626	3087	715	24	Privado	47581	48	2	☐				
☐	2	Row1	2	2023-04-26	29	Femenino	Divorciado	Guayaquil	861	561	434	1	Privado	29226	48	4	☐				
☐	3	Row2	3	2025-01-20	28	Femenino	Divorciado	Ambato	3095	2657	659	8	Dependiente	46405	60	4	☐				
☐	4	Row3	4	2023-01-07	60	Masculino	Divorciado	Quito	5642	3610	472	21	Dependiente	33362	48	1	☐				
☐	5	Row4	5	2024-04-12	41	Masculino	Casado	Quito	1463	2481	392	17	Privado	12010	48	3	☐				
☐	6	Row5	6	2024-12-21	19	Masculino	Soltero	Manta	774	1595	720	14	Independiente	12675	36	2	☐				
☐	7	Row6	7	2023-06-07	45	Femenino	Divorciado	Ambato	5529	1826	832	23	Publico	28704	24	4	☐				
☐	8	Row7	8	2024-12-06	38	Masculino	Casado	Manta	2389	409	866	0	Publico	21994	48	2	☐				
☐	9	Row8	9	2023-04-20	27	Masculino	Divorciado	Guayaquil	5424	3431	326	7	Publico	30038	60	5	☐				
☐	10	Row9	10	2024-11-23	31	Masculino	Divorciado	Guayaquil	4571	2745	463	3	Publico	19210	36	3	☐				
☐	11	Row10	11	2023-02-18	19	Femenino	Divorciado	Manta	4768	512	519	21	Independiente	33747	36	8	☐				
☐	12	Row11	12	2024-07-29	44	Masculino	Divorciado	Ambato	2123	2174	846	9	Dependiente	15550	60	7	☐				

Tabla View

Excel Reader

Table View

Carga inicial del dataset bancario utilizado para el análisis predictivo de aprobación de créditos.

Add comment

Table View

Data

Displayed columns

Manual Wildcard Regex Type

Search

Search

Excludes

Includes

id_cliente
fecha_solicitud
edad
genero
estado_civil
ciudad
ingresos_mensuales
gastos_mensuales
score_credito
antiguedad_lab
tipo_empleo
monto_solicitado
plazo_meses
productos_bancarios

Discard

Apply and Execute

Apply

View Flow Variables

Table View

Open in new window

Rows: 5000 | Columns: 18

RowID	id_cliente	fecha_solicitud	edad	genero	estado_civil	ciudad	ingresos_mensuales	gastos_mensuales	score_credito	antiguedad_lab	tipo_empleo	monto_solicitado	plazo_meses	productos_bancarios
Row0	1	2024-04-26	66	Masculino	Casado	Manta	2626	3087	715	24	Privado	47891	48	2
Row1	2	2023-04-26	29	Femenino	Divorciado	Guayaquil	861	561	434	1	Privado	29226	48	4
Row2	3	2025-01-20	28	Femenino	Divorciado	Ambato	3095	2657	659	8	Dependiente	46405	60	4
Row3	4	2023-01-07	60	Masculino	Divorciado	Quito	5642	3610	472	21	Dependiente	39362	48	1
Row4	5	2024-04-12	41	Masculino	Casado	Quito	1463	2431	392	17	Privado	12010	48	3
Row5	6	2024-12-21	19	Masculino	Soltero	Manta	774	1595	720	14	Independiente	12675	36	2

Statistics

Excel Reader

Table View

Statistics

Statistics

Nominal Values

ciudad
ingresos_mensuales
gastos_mensuales
score_credito
antiguedad_lab
tipo_empleo
monto_solicitado
plazo_meses
productos_bancarios

Max no. of most frequent and infrequent values (in view)

20

Max no. of possible values per column (in output table)

19000

Discard

Apply and Execute

Apply

Statistics Table

Nominal Histogram Table

Occurrences Table

Flow Variables

Rows: 11 | Columns: 16

#	RowID	Column	Min	Max	Mean	Std. dev.	Variance	Skewness	Kurtosis	Overall su...	No. miss...	No. NaNs	No. +00s	No. -00s	M
1	id_cliente	id_cliente	1	5,000	2,500.5	1,440.52	2,063,750	0	-1.2	12,502,500	0	0	0	0	0
2	edad	edad	18	69	43.657	15.181	228.956	-0.04	-1.217	219,284	0	0	0	0	0
3	ingresos	ingresos_mensua	500	6,000	3,260.934	1,585.621	2,514,193.497	-0.017	-1.191	16,301,970	0	0	0	0	0
4	gastos	gastos_mensua	301	4,000	2,135.977	1,076.66	1,159,195.869	0.001	-1.2	10,792,984	0	0	0	0	0
5	score_c	score_credito	300	900	600.466	172.315	29,692.322	-0.02	-1.202	3,002,340	0	0	0	0	0
6	antigued	antiguedad_lab	0	30	14.924	8.787	77.22	0	-1.167	74,619	0	0	0	0	0
7	monto_s	monto_solicitado	1,000	49,999	25,625.972	14,935.460	205,505,498.127	-0.019	-1.24	128,125,361	0	0	0	0	0
8	plazo_m	plazo_meses	12	60	36.067	17.057	290.934	-0.009	-1.312	180,336	0	0	0	0	0
9	produc	productos_banc	1	7	3.978	1.995	3.981	0.925	-1.249	19,891	0	0	0	0	0
10	capacit	capacidad_pago	-3,457	5,554	1,101.797	1,939.256	3,760,712.305	-0.009	-0.673	5,596,986	0	0	0	0	0
11	credito	credito_aprobad	0	1	0.53	0.499	0.249	-0.12	-1.986	2,650	0	0	0	0	0

Missing Value

Dataset completo y consistente para las siguientes fases del proceso analítico.

Objetivo:
Generar un dataset consistente de la información utilizada en el proceso analítico.

Acción:
- Imputación y reemplazo de valores faltantes.
- Generación de reportes estadísticos.
- Selección de variables de alto rendimiento.
- Preparación de datos para modelos predictivos.

Notas de configuración:
- Columna Filter:
- Aplicación de filtros de datos.
- Selección de variables de alto rendimiento para obtener resultados consistentes en los modelos de Machine Learning.
- Resultados esperados:
- Generación de un dataset completo y consistente para el análisis de datos y resultados predictivos.

Missing Value Treatment by Column

Treatment by Data Type

Number (Integer)
Treatment: Mean

String
Treatment: Most Frequent Value

Discard Apply and Execute Apply

1: Output Table 2: PMML Transformations Flow Variables

Rows: 5000 Columns: 18

#	RowID	id_cliente	fecha_sol...	edad	genero	estado_civil	ciudad	ingresos_m...	gastos_m...	score_cre...	antigueda...	tipo_empl...	monto_so...	plazo_me...
1	Row0	1	2024-04-26	66	Masculino	Casado	Manta	2,626	3,067	715	24	Privado	47,561	48
2	Row1	2	2023-04-26	29	Femenino	Divorciado	Guayaquil	861	561	434	1	Privado	29,226	48
3	Row2	3	2025-01-20	28	Femenino	Divorciado	Ambato	3,095	2,657	659	8	Dependiente	46,405	60
4	Row3	4	2023-01-07	60	Masculino	Divorciado	Quito	5,642	3,610	472	21	Dependiente	33,362	48
5	Row4	5	2024-04-12	41	Masculino	Casado	Quito	1,463	2,481	392	17	Privado	12,010	48
6	Row5	6	2024-12-21	19	Masculino	Soltero	Manta	774	1,595	720	14	Independiente	12,675	36
7	Row6	7	2023-06-07	45	Femenino	Divorciado	Ambato	5,529	1,826	832	23	Público	28,704	24
8	Row7	8	2024-12-06	38	Masculino	Casado	Manta	2,380	409	366	0	Público	21,994	48
9	Row8	9	2023-04-20	27	Masculino	Divorciado	Guayaquil	5,424	3,431	326	7	Público	30,088	60
10	Row9	10	2024-11-28	31	Masculino	Divorciado	Guayaquil	4,571	2,745	463	3	Público	19,210	36
11	Row10	11	2023-02-18	19	Femenino	Divorciado	Manta	4,768	512	519	21	Independiente	33,747	36
12	Row11	12	2024-07-29	44	Masculino	Divorciado	Ambato	2,128	2,174	846	9	Dependiente	15,550	60

Tratamiento de Valores Faltantes

Objetivo:

Corregir registros incompletos para garantizar la calidad de los datos.

Configuración aplicada:

- Variables numéricas: reemplazo mediante media.
- Variables categóricas: reemplazo mediante valor más frecuente.

Justificación:

La imputación permite conservar registros relevantes evitando pérdida de información durante el análisis y modelado.

Resultado esperado:

Dataset completo y consistente para las siguientes fases del proceso analítico.

1- Filtered/Labeled Data **Flow Variables**

Rows: 5000 | Columns: 18

#	RowID	id_cliente	fecha_sol...	edad	genero	estado_civil	ciudad	ingresos...	gastos_m...	score_cre...	antigüeda...	tipo_empl...	monto_so...	plazo_me...
1	Row0	1	2024-04-26	66	Masculino	Casado	Manta	2,626	3,067	715	24	Privado	47,561	48
2	Row1	2	2023-04-26	29	Femenino	Divorciado	Guayaquil	961	561	494	1	Privado	29,226	48
3	Row2	3	2025-01-20	28	Femenino	Divorciado	Ambato	3,095	2,657	659	8	Dependiente	46,405	60
4	Row3	4	2023-01-07	60	Masculino	Divorciado	Quito	5,642	3,610	472	21	Dependiente	33,362	48
5	Row4	5	2024-04-12	41	Masculino	Casado	Quito	1,463	2,461	392	17	Privado	12,010	48
6	Row5	6	2024-12-21	19	Masculino	Soltero	Manta	774	1,595	720	14	Independiente	12,675	36
7	Row6	7	2023-06-07	45	Femenino	Divorciado	Ambato	5,529	1,626	632	23	Publico	28,704	24
8	Row7	8	2024-12-06	38	Masculino	Casado	Manta	2,380	499	366	9	Publico	21,594	48
9	Row8	9	2023-04-20	27	Masculino	Divorciado	Guayaquil	5,424	3,431	326	7	Publico	30,098	60
10	Row9	10	2024-11-28	31	Masculino	Divorciado	Guayaquil	4,571	2,745	463	3	Publico	19,210	36
11	Row10	11	2023-02-18	19	Femenino	Divorciado	Manta	4,766	512	519	21	Independiente	33,747	36
12	Row11	12	2024-07-29	44	Masculino	Divorciado	Ambato	2,128	2,174	846	9	Dependiente	15,550	60

Eliminación de Registros Duplicados

Objetivo:

Identificar y eliminar posibles registros repetidos dentro del dataset.

Configuración:

- Detección basada en el identificador único del cliente (id_cliente).

Justificación:

Cada cliente debe estar representado por un único registro para evitar sesgos en el análisis y el entrenamiento de modelos predictivos.

Resultado esperado:

Conjunto de datos libre de duplicidades.

Column Filter

Column Filter

Manual Wildcard Regex Type

Search

Excludes

- id_cliente

Includes

- fecha_solicitud
- edad
- genero
- estado_civil
- ciudad
- ingresos_mensuales
- gastos_mensuales
- score_credito
- antigüedad_laboral

Discard Apply and Execute Apply

► 1: Filtered Table ◀ Flow Variables

No data | Columns: 18

id_cliente	fecha_solicitud	edad	genero	estado_civil	ciudad	ingresos_mensuales	gastos_mensuales	score_credito	antigüedad_laboral	tipo_empleo	monto_solicitud	plazo_meses	productos_bancarios	mora_historial
1	2023-04-26	66	Masculino	Casado	Manta	2,626	3,967	715	24	Privado	47,501	48	2	Si
2	2023-04-26	23	Femenino	Divorciado	Guayaquil	981	591	404	1	Privado	29,326	48	4	Si
3	2023-01-29	28	Femenino	Divorciado	Ambato	3,995	2,657	659	8	Dependiente	46,805	60	4	No
4	2023-01-07	69	Masculino	Divorciado	Quito	5,642	3,819	472	21	Dependiente	33,362	48	1	No
5	2024-04-12	41	Masculino	Casado	Quito	1,463	2,431	392	17	Privado	12,910	48	3	No
6	2024-12-21	19	Masculino	Soltero	Manta	774	1,595	729	14	Independiente	12,675	36	2	No
7	2023-06-07	45	Femenino	Divorciado	Ambato	5,529	1,826	832	28	Publico	28,794	24	4	Si
8	2023-12-06	38	Masculino	Casado	Manta	2,309	409	366	0	Publico	21,994	48	2	No
9	2023-04-29	27	Masculino	Divorciado	Guayaquil	5,424	3,431	326	7	Publico	30,998	60	5	No
10	2024-11-28	31	Masculino	Divorciado	Guayaquil	4,571	2,745	463	8	Publico	19,310	36	3	Si
11	2023-02-18	19	Femenino	Divorciado	Manta	4,766	512	519	21	Independiente	33,747	36	1	No

To show the port output, execute the selected node.

► Execute

Column Filter

Manual Wildcard Regex Type

Search

Excludes

- id_cliente

Includes

- fecha_solicitud
- edad
- genero
- estado_civil
- ciudad
- ingresos_mensuales
- gastos_mensuales
- score_credito
- antigüedad_laboral

Discard Apply and Execute Apply

► 1: Filtered Table ◀ Flow Variables

Rows: 5000 | Columns: 17

#	RowID	fecha_solicitud	edad	genero	estado_civil	ciudad	ingresos_mensuales	gastos_mensuales	score_credito	antigüedad_laboral	tipo_empleo	monto_solicitud	plazo_meses	productos_bancarios	mora_historial
1	Row0	2023-04-26	66	Masculino	Casado	Manta	2,626	3,967	715	24	Privado	47,501	48	2	Si
2	Row1	2023-04-26	23	Femenino	Divorciado	Guayaquil	981	591	404	1	Privado	29,326	48	4	Si
3	Row2	2023-01-29	28	Femenino	Divorciado	Ambato	3,995	2,657	659	8	Dependiente	46,805	60	4	No
4	Row3	2023-01-07	69	Masculino	Divorciado	Quito	5,642	3,819	472	21	Dependiente	33,362	48	1	No
5	Row4	2024-04-12	41	Masculino	Casado	Quito	1,463	2,431	392	17	Privado	12,910	48	3	No
6	Row5	2024-12-21	19	Masculino	Soltero	Manta	774	1,595	729	14	Independiente	12,675	36	2	No
7	Row6	2023-06-07	45	Femenino	Divorciado	Ambato	5,529	1,826	832	28	Publico	28,794	24	4	Si
8	Row7	2023-12-06	38	Masculino	Casado	Manta	2,309	409	366	0	Publico	21,994	48	2	No
9	Row8	2023-04-29	27	Masculino	Divorciado	Guayaquil	5,424	3,431	326	7	Publico	30,998	60	5	No
10	Row9	2024-11-28	31	Masculino	Divorciado	Guayaquil	4,571	2,745	463	8	Publico	19,310	36	3	Si
11	Row10	2023-02-18	19	Femenino	Divorciado	Manta	4,766	512	519	21	Independiente	33,747	36	1	No

Selección de Variables Analíticas

Objetivo:

Conservar únicamente las variables relevantes para el análisis y modelado predictivo.

Variable excluida:

- id_cliente

Justificación:

Corresponde a un identificador técnico utilizado para distinguir registros y no aporta capacidad predictiva sobre la aprobación del crédito.

Resultado esperado:

Dataset optimizado para las fases de transformación y modelado.

Math Formula

FASE 4. TRANSFORMACIÓN Y ENRIQUECIMIENTO DE DATOS

Objetivo:

Generar variables derivadas que representen de mejor manera la situación financiera de los clientes.

Actividades:


- Construcción de indicadores financieros.
- Creación de variables derivadas para análisis y modelado.
- Preparación de atributos de negocio.

Nodos utilizados:

- Math Formula
- Rule Engine

Resultado esperado:

Incrementar el valor analítico de los datos mediante la incorporación de nuevas variables.



Variable creada:


ratio_endeudamiento

Fórmula:

$\text{gastos_mensuales} / \text{ingresos_mensuales}$

Interpretación:

Mide qué porcentaje de los ingresos del cliente se encuentra comprometido por sus gastos mensuales. Valores altos indican mayor presión financiera y potencial riesgo crediticio.



Clasificación de Riesgo Crediticio

Objetivo:

Segmentar a los clientes en categorías de riesgo para facilitar el análisis y la interpretación de resultados.

Variable creada:

segmento_riesgo

Reglas aplicadas:


- Score menor a 500 = Alto Riesgo.
- Score entre 500 y 699 = Riesgo Medio.
- Score mayor o igual a 700 = Bajo Riesgo.

Justificación:


El score crediticio es uno de los indicadores más utilizados en la evaluación de riesgo financiero y permite clasificar clientes según su probabilidad de incumplimiento.

Resultado esperado:

Obtención de segmentos de clientes que faciliten el análisis exploratorio y la construcción de modelos predictivos.



Análisis de Datos



Histograma de Score Crediticio

Objetivo:


Analizar la distribución de los puntajes crediticios de los clientes.


Interpretación esperada:

Permite identificar la concentración de clientes en diferentes niveles de score crediticio y detectar posibles segmentos de riesgo.

Valor para el negocio:

Ayuda a comprender el perfil financiero de la cartera de clientes y su potencial nivel de riesgo.





La distribución del score crediticio evidencia la concentración de clientes en rangos medios y altos, lo que permite inferir un perfil de riesgo moderado dentro de la muestra analizada. Esta variable constituye uno de los principales factores utilizados en los procesos de evaluación crediticia.




Figura X. Distribución de ingresos mensuales por segmento de riesgo.

El análisis mediante diagramas de caja permitió comparar la distribución de ingresos mensuales entre los diferentes segmentos de riesgo crediticio. Se observa que los clientes clasificados en los distintos niveles presentan variabilidad en sus ingresos, permitiendo identificar patrones financieros relevantes para la evaluación crediticia. Este análisis facilita la comprensión de la relación existente entre la capacidad económica de los clientes y su perfil de riesgo.

Análisis de Ingresos por Segmento de Riesgo

Objetivo:

Comparar la distribución de ingresos mensuales entre los diferentes segmentos de riesgo generados mediante el score crediticio.

Variables:

- ingresos_mensuales
- segmento_riesgo

Resultado esperado:

Identificar diferencias en la capacidad económica de los clientes según su nivel de riesgo.

Relación entre Ingresos y Monto Solicitado

Objetivo:

Analizar la relación existente entre la capacidad económica del cliente y el monto de crédito solicitado.

Variables:

- ingresos_mensuales
- monto_solicitado

Interpretación:

Permite identificar tendencias, agrupaciones y posibles patrones de comportamiento financiero dentro de la cartera analizada.

Valor para el negocio:

Facilita la comprensión de la relación entre ingresos y capacidad potencial de endeudamiento.




Figura X. Relación entre ingresos mensuales y monto solicitado.

El análisis de dispersión evidencia una amplia variabilidad en los montos solicitados para todos los niveles de ingreso. No se identifica una relación lineal claramente definida entre ambas variables, lo que sugiere que otros factores como score crediticio, historial de mora, capacidad

de pago y antigüedad laboral podrían influir significativamente en la aprobación y características del crédito solicitado.

Análisis de Correlación

Objetivo:

Identificar la intensidad de la relación lineal entre las variables numéricas del dataset.

Variables analizadas:

- edad
- ingresos_mensuales
- gastos_mensuales
- score_credificio
- antigüedad_laboral
- monto_solicitado
- plazo_meses
- capacidad_pago
- ratio_endeudamiento

Interpretación:

La matriz de correlación permite identificar variables con mayor influencia potencial sobre la aprobación crediticia y detectar relaciones significativas entre atributos financieros.

Análisis de Correlación

Objetivo:

Identificar relaciones entre variables numéricas del dataset.

Variables analizadas:

- edad

- ingresos_mensuales
- gastos_mensuales
- score_credificio
- antigüedad_laboral
- monto_solicitado
- plazo_meses
- capacidad_pago
- ratio_endeudamiento

Resultado esperado:

Identificar variables con mayor influencia potencial sobre la aprobación crediticia.

FASE 6. MODELADO PREDICTIVO

Objetivo:

Desarrollar modelos de Machine Learning capaces de predecir la aprobación de créditos utilizando información histórica de clientes.

Actividades:

- División del dataset en entrenamiento y prueba.
- Construcción de modelos supervisados.
- Generación de predicciones.
- Comparación de desempeño entre algoritmos.

Nodos utilizados:

- Partitioning
- Decision Tree Learner
- Decision Tree Predictor

- Random Forest Learner
- Random Forest Predictor

Resultado esperado:

Obtención de modelos predictivos capaces de apoyar la toma de decisiones crediticias.

FASE 5. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Objetivo:

Explorar patrones, tendencias y relaciones presentes en los datos para comprender los factores asociados a la aprobación crediticia.

Actividades:



- Análisis de distribuciones.
- Comparación entre segmentos de riesgo.
- Evaluación de relaciones entre variables financieras.
- Identificación de correlaciones.

Nodos utilizados:

- Statistics
- Histogram
- Box Plot
- Scatter Plot
- Linear Correlation

Resultado esperado:

Obtención de información relevante para apoyar la construcción de modelos predictivos.



Análisis de Correlación

Objetivo:

Identificar relaciones lineales entre variables numéricas relevantes para el análisis crediticio.

Variables consideradas:

- edad
- ingresos_mensuales
- gastos_mensuales
- score_crediticio
- antigüedad_laboral
- monto_solicitado
- plazo_meses
- productos_bancarios
- capacidad_pago
- credito_aprobado
- ratio_endeudamiento

Interpretación:

Los coeficientes de correlación permiten identificar relaciones positivas o negativas entre variables financieras y de riesgo, apoyando la selección de atributos para el modelado predictivo.

Resultado esperado:

Identificación de variables con mayor influencia potencial sobre la aprobación crediticia.

INTERPRETACIÓN

Basado en los resultados que veo:

$\text{capacidad_pago} \leftrightarrow \text{ingresos_mensuales} = 0.832$

Esta es una correlación positiva fuerte.

También veo:

$\text{ratio_endeudamiento} \leftrightarrow \text{capacidad_pago} = -0.798$

Correlación negativa fuerte.

Y:

$\text{score_crediticio} \leftrightarrow \text{credito_aprobado} = 0.416$

Correlación positiva moderada.

El análisis de correlación permitió identificar relaciones relevantes entre las variables financieras del dataset. Se observó una fuerte correlación positiva entre ingresos mensuales y capacidad de pago (0.832), indicando que clientes con mayores ingresos presentan una mayor capacidad financiera. Asimismo, se evidenció una fuerte correlación negativa entre ratio de endeudamiento y capacidad de pago (-0.798), lo que sugiere que niveles elevados de endeudamiento reducen significativamente la capacidad financiera del cliente. Finalmente, el score crediticio presentó una correlación positiva moderada con la aprobación del crédito (0.416), confirmando su relevancia dentro del proceso de evaluación crediticia.

FASE 6. MODELADO PREDICTIVO

FASE 6. MODELADO PREDICTIVO

Objetivo:

Construir modelos de Machine Learning para predecir la aprobación de créditos utilizando información histórica de clientes.

Actividades:

- División de datos para entrenamiento y validación.
- Construcción de modelos supervisados.
- Generación de predicciones.
- Evaluación del desempeño.

Modelos:

- Decision Tree.
- Tree Ensemble (Random Forest).

Resultado esperado:

Obtención de modelos capaces de apoyar la toma de decisiones crediticias.

Validación Cruzada (10-Fold Cross Validation)

Objetivo:

Evaluar el desempeño de los modelos predictivos mediante validación cruzada.

Configuración:

- 10 particiones.
- Muestreo estratificado.
- Conservación de la distribución de la variable objetivo.

Justificación:

La validación cruzada permite obtener una estimación más robusta y confiable del desempeño de los modelos, reduciendo el riesgo de sobreajuste.

Resultado esperado:

Obtención de métricas de evaluación representativas del comportamiento real del modelo.

Conversión de Variable Objetivo

Objetivo:



Transformar la variable `credito_aprobado` desde formato numérico a categórico para permitir la ejecución de algoritmos de clasificación supervisada.

Herramienta utilizada:

- Number To String

Justificación:

Los algoritmos de clasificación requieren una variable objetivo categórica para construir modelos predictivos orientados a la toma de decisiones.



Codificación de Variables Categóricas

Objetivo:

Transformar variables categóricas en variables numéricas mediante One-Hot Encoding para facilitar el entrenamiento de modelos predictivos.

Variables transformadas:

- genero
- estado_civil
- ciudad
- tipo_empleo
- mora_historica
- canal_solicitud
- segmento_riesgo

Justificación:

Los algoritmos de Machine Learning requieren variables numéricas para optimizar el proceso de entrenamiento y mejorar la interpretación de resultados.

Resultado esperado:

Generación de variables binarias representativas de las categorías originales.

PREDICCIÓN DEL MODELO

Objetivo:

Aplicar el modelo de Árbol de Decisión entrenado sobre el conjunto de datos de prueba.

Entradas:


- Modelo entrenado.
- Datos de prueba (30%).

Proceso:

El modelo genera una predicción para cada solicitud de crédito.

Resultado esperado:

Obtención de la clasificación predicha de aprobación o rechazo de crédito para cada cliente.



FASE 8. EVALUACIÓN DEL MODELO

Objetivo:

Evaluar el desempeño del Árbol de Decisión mediante métricas de clasificación.

Métricas:

- Accuracy
- Precision
- Recall



- F1-Score
- Matriz de Confusión

Justificación:

Permite determinar la capacidad predictiva del modelo y su utilidad para apoyar decisiones crediticias.

Resultado esperado:

Obtención de indicadores cuantitativos del desempeño del modelo.



MODELO 2. RANDOM FOREST

Objetivo:


Construir un modelo de ensamble basado en múltiples árboles de decisión.

Ventajas:

- Mayor precisión.
- Menor sobreajuste.
- Mayor robustez.

Resultado esperado:

Comparar su desempeño frente al Árbol de Decisión y seleccionar el mejor modelo.



MODELO 2: RANDOM FOREST

Objetivo:

Construir un modelo de clasificación basado en múltiples árboles de decisión para mejorar la precisión predictiva.

Entradas:


- Datos de entrenamiento (70%).
- Variable objetivo: credito_aprobado.

Ventajas:

- Reduce el sobreajuste.
- Incrementa la robustez del modelo.
- Mejora la capacidad de generalización.

Resultado esperado:

Generar predicciones más precisas para la aprobación de créditos y comparar su desempeño frente al Árbol de Decisión.



Modelo 1: Random Forest (primera imagen)

- Accuracy = **0.999 (99.9%)**
- Precision = **0.999**
- Recall = **0.999**
- F1-Score = **0.999**
- Cohen's Kappa = **0.997**

Errores:

- Solo 2 clasificaciones incorrectas de 1500 registros.

Modelo 2: Árbol de Decisión (segunda imagen)

- Accuracy = **0.998 (99.8%)**
- Precision ≈ **0.997 - 0.999**

- Recall $\approx$ **0.997 - 0.999**
- F1-Score $\approx$ **0.998**
- Cohen's Kappa = **0.996**

Errores:

- 3 clasificaciones incorrectas de 1500 registros.

Conclusión

Se evaluaron dos modelos de clasificación: Árbol de Decisión y Random Forest. Ambos alcanzaron resultados sobresalientes con niveles de precisión superiores al 99%. Sin embargo, el modelo Random Forest presentó el mejor desempeño global, obteniendo una exactitud del 99.9%, superando ligeramente al Árbol de Decisión (99.8%). Debido a su mayor capacidad de generalización y menor número de errores de clasificación, se selecciona Random Forest como el modelo recomendado para la aprobación automática de créditos.

Modelo ganador

Random Forest

Métricas finales:

- Accuracy: **99.9%**
- Precision: **99.9%**
- Recall: **99.9%**
- F1-Score: **99.9%**
- Kappa: **0.997**